R6.B.05 – OPTIMISATION DE SERVICES COMPLEXES

PARTIE II

Edward Staddon

Edward.Staddon@univ-ubs.fr

Université Bretagne Sud, IUT de Vannes, Département Informatique



PLAN DU COURS

- Optimisation de l'accès aux ressources
- Réseau de diffusion de contenus
- Introduction à la qualité de service

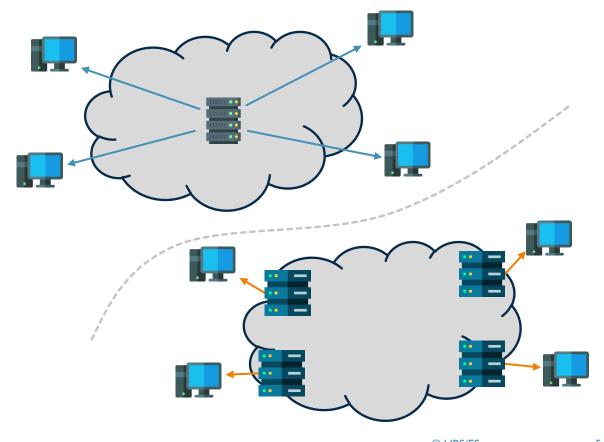
PLAN DU COURS

- Optimisation de l'accès aux ressources
- Réseau de diffusion de contenus
- Introduction à la qualité de service

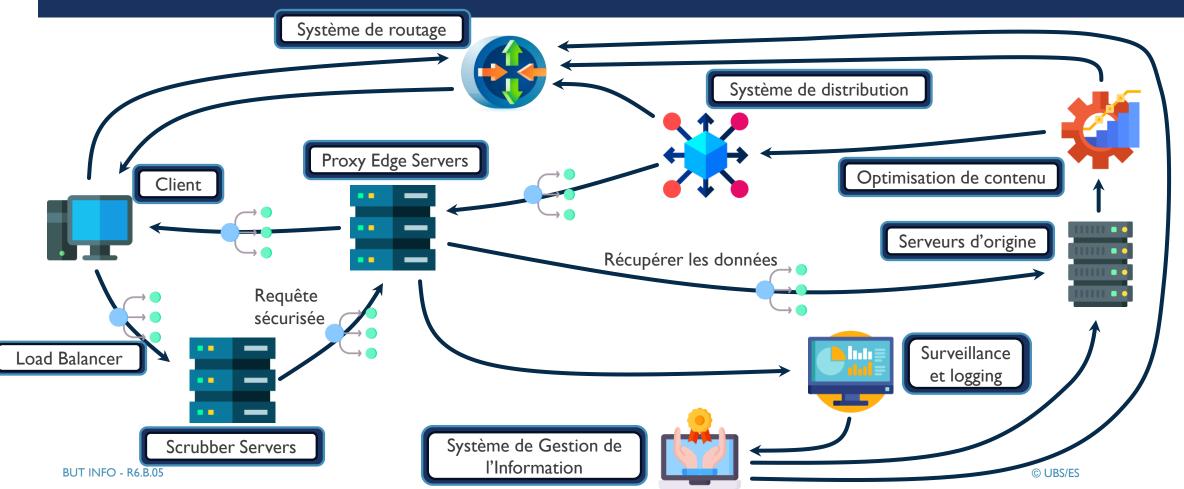
RÉSEAU DE DIFFUSION DE CONTENUS

RÉSEAU DE DIFFUSION DE CONTENUS ?

- RDC (Content Delivery Network : CDN)
 - Ensemble de serveurs distribués
 - Stockent temporairement des contenus web (cache)
 - HTML, JS, CSS, images, vidéos, etc ...
 - Situés proche des utilisateurs
- De plus en plus populaires
 - Vaste majorité du trafic web servi par des CDN
 - Ex: Facebook, Netflix, Amazon, Steam, ...
- Ne remplace pas l'hébergement!
 - Mise en cache à la périphérie du réseau



ARCHI ... QUOI?

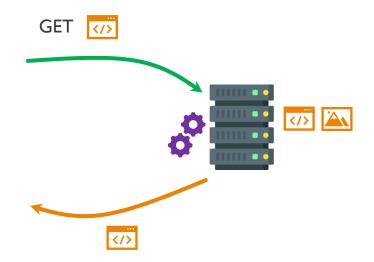


COMMENT CA MARCHE?



QU'EST CE QU'ON « SERVEUR D'ORIGINE »

- Serveur qui traite et répond aux requêtes Internet
- Entièrement responsable de la diffusion de contenu d'une propriété Internet
 - Site Web
- Peut fournir plusieurs types de données
 - Statiques
 - Web HTML, JS, CSS, Image → données génériques
 - Dynamiques
 - PHP, Node.Js, etc... → données personnalisées











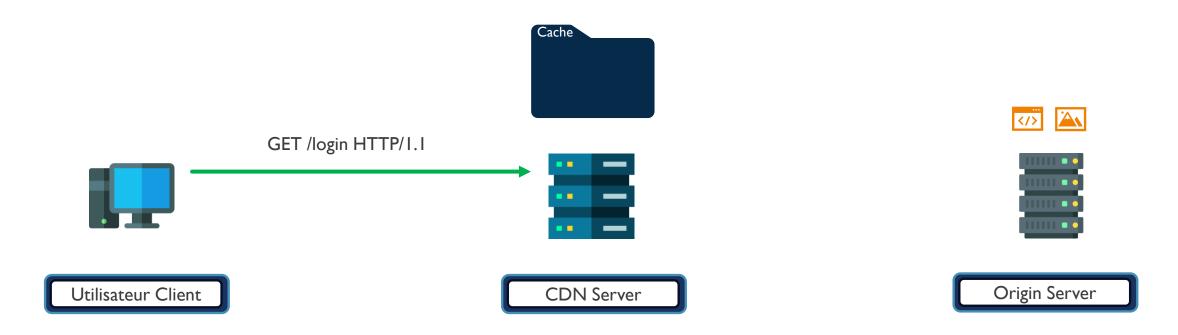








Origin Server





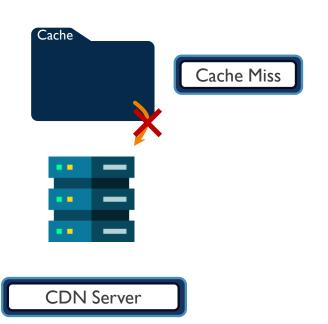
Utilisateur Client







Utilisateur Client





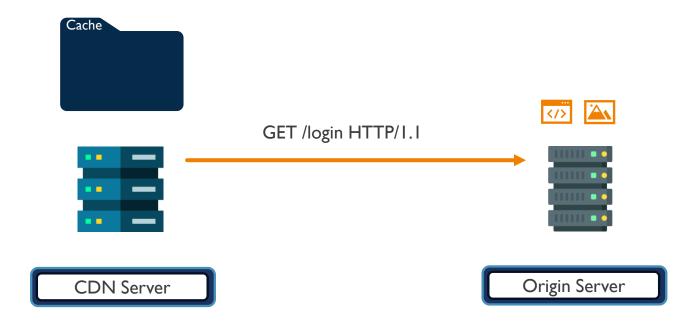




Origin Server

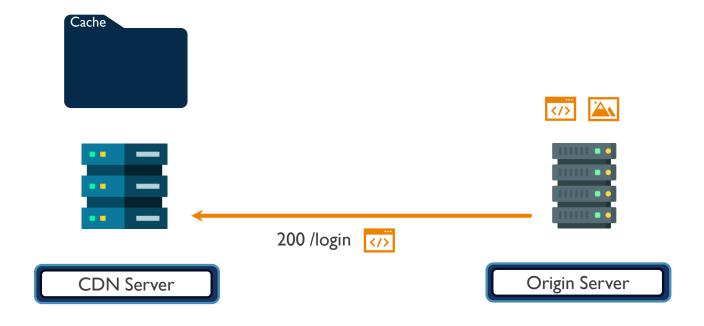


Utilisateur Client



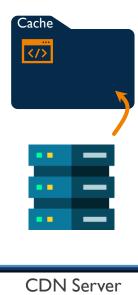


Utilisateur Client



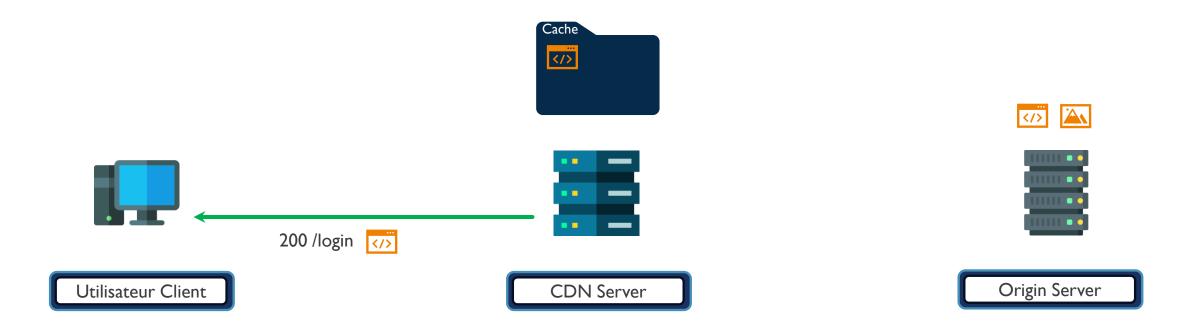


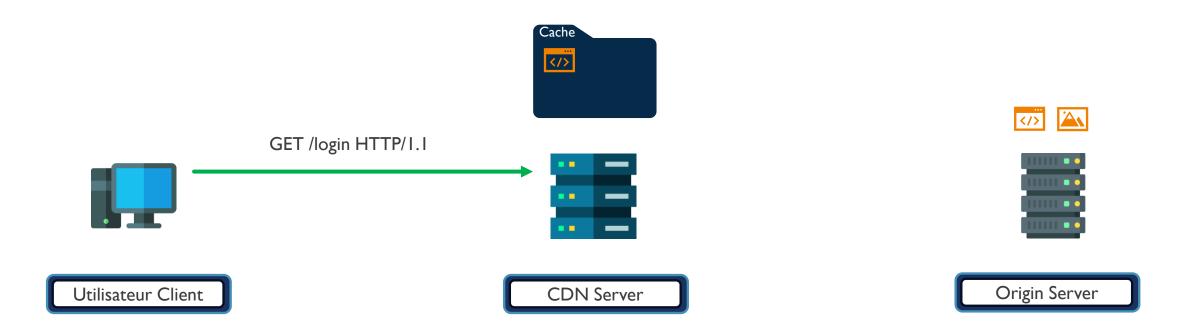
Utilisateur Client













Utilisateur Client





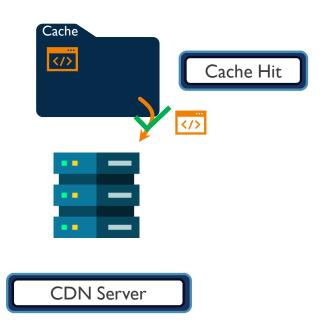








Utilisateur Client

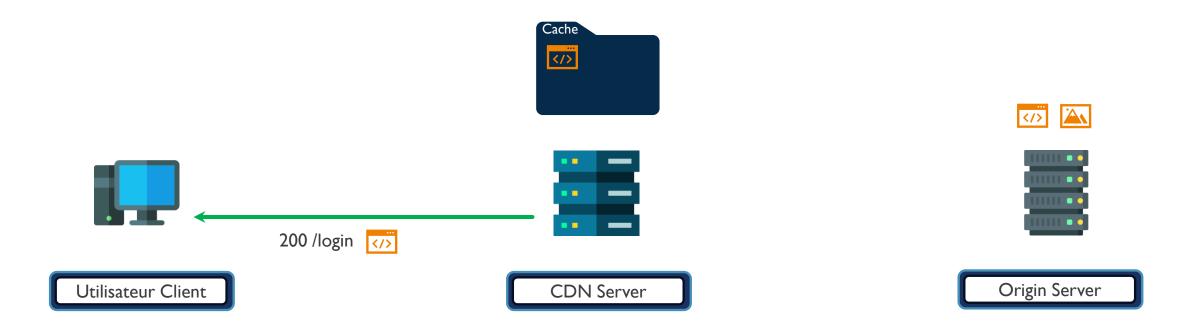


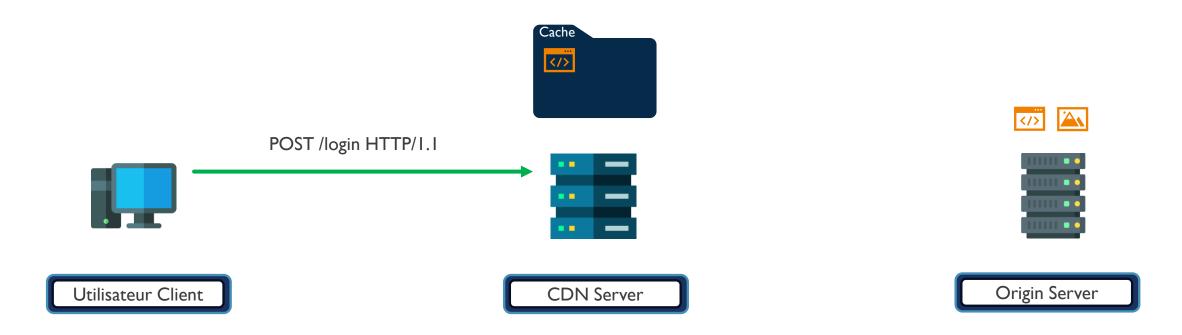






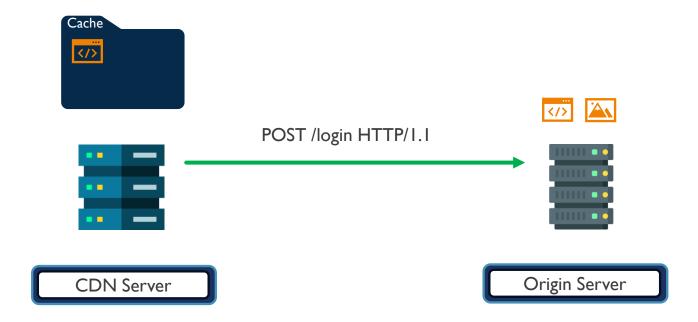
Origin Server





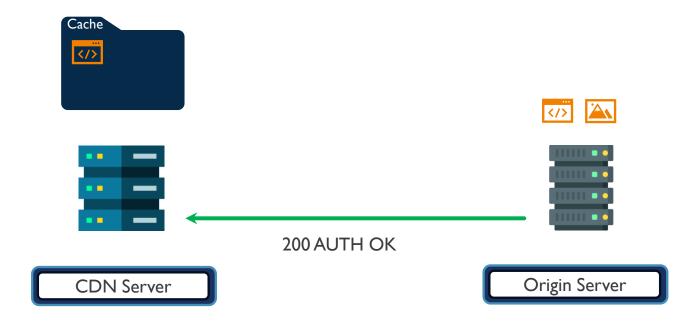


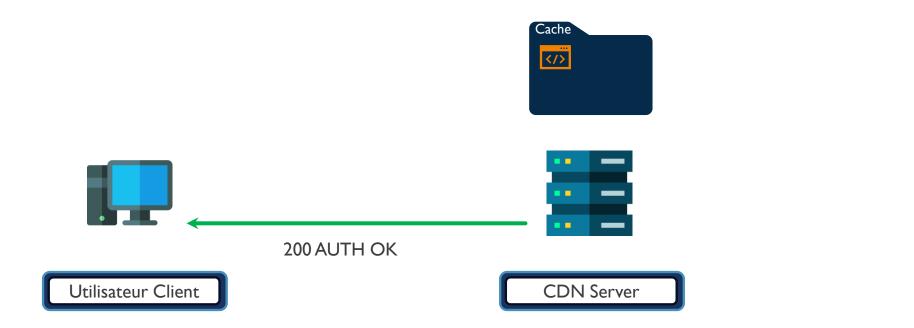
Utilisateur Client





Utilisateur Client



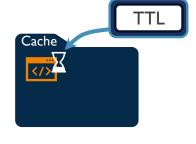








Origin Server

















Utilisateur Client





















Utilisateur Client





CDN Server





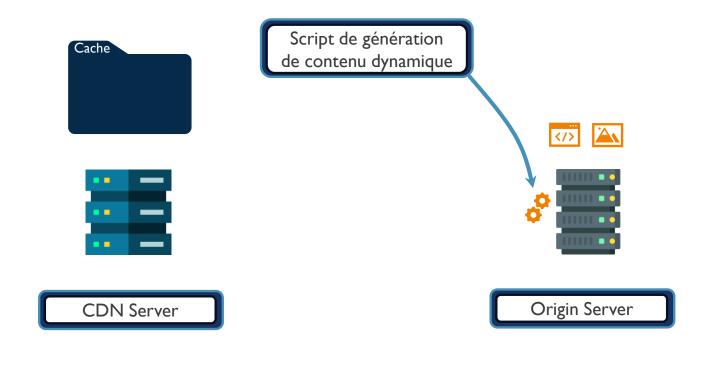


Origin Server





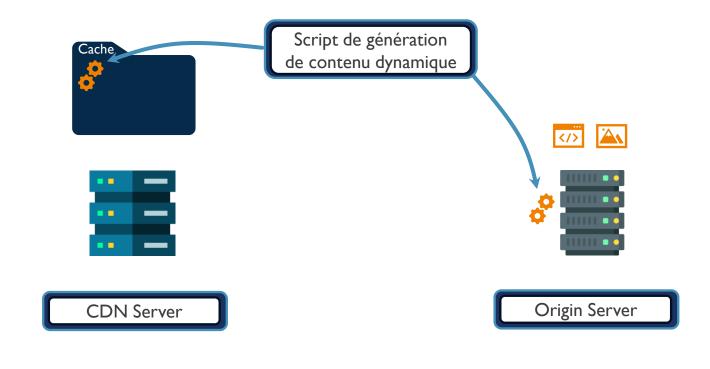
Utilisateur Alice

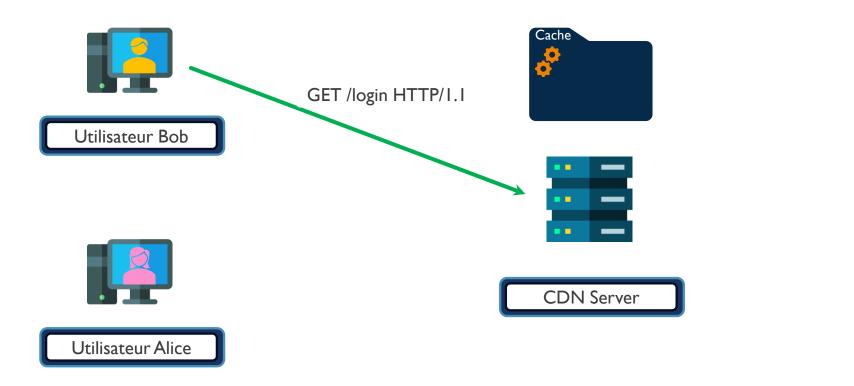


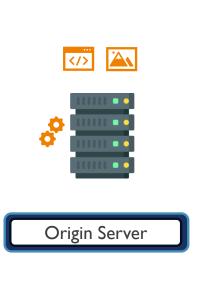




Utilisateur Alice





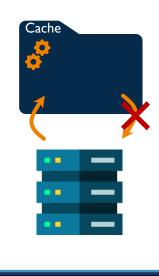




Utilisateur Bob



Utilisateur Alice









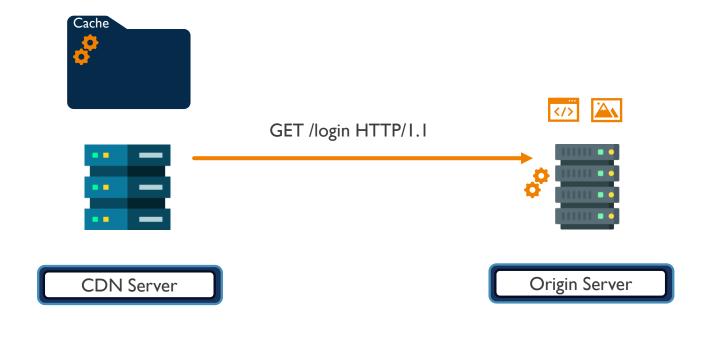








Utilisateur Alice



BUT INFO - R6.B.05

© UBS/ES



Utilisateur Bob



Utilisateur Alice





CDN Server



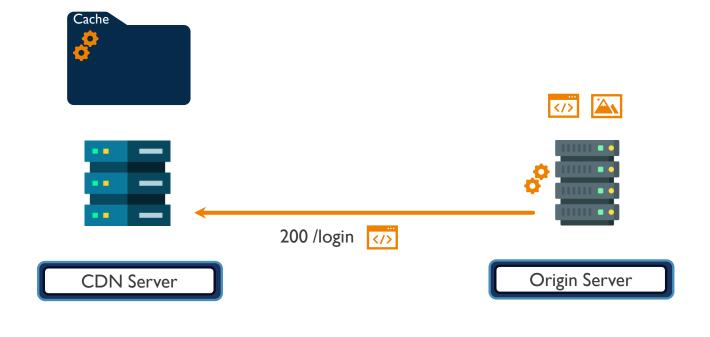




Origin Server









Utilisateur Bob



Utilisateur Alice





CDN Server







Origin Server

BUT INFO - R6.B.05

© UBS/ES



Utilisateur Bob



Utilisateur Alice





CDN Server





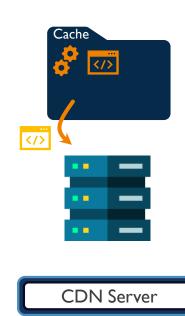


Origin Server

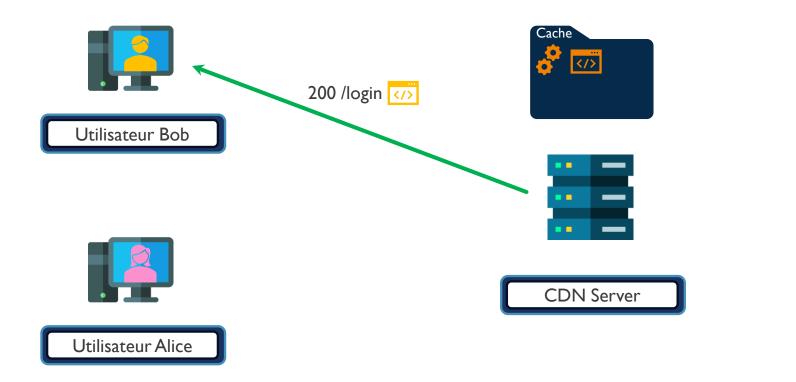




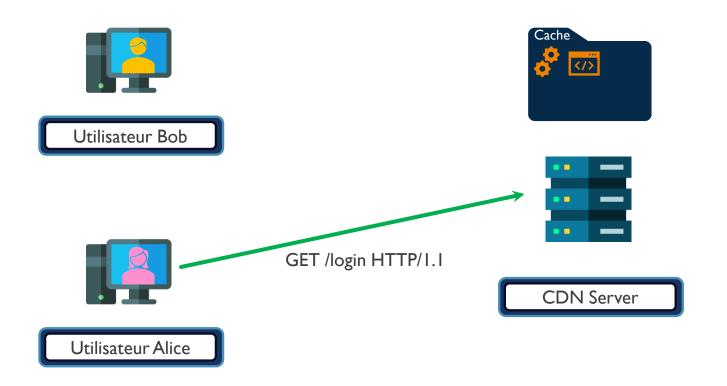
Utilisateur Alice











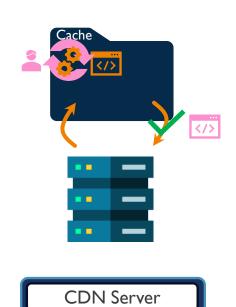




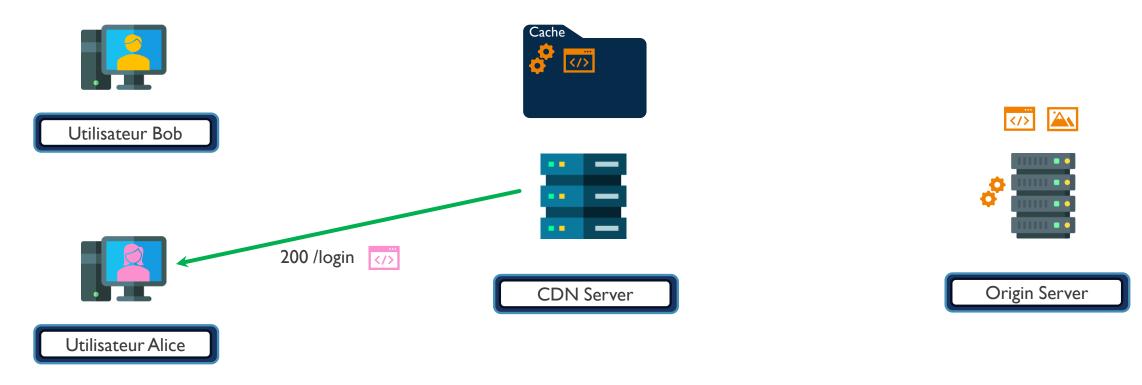
Utilisateur Bob



Utilisateur Alice







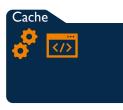
CHARGEMENT DE CONTENU



Utilisateur Bob



Utilisateur Alice



Indicateur de performance

Taux d'accès au cache

$$Taux = \frac{nombre_{hits}}{nombre_{hits} + nombre_{misses}}$$

Plus la valeur est élevée → plus le cache est efficace



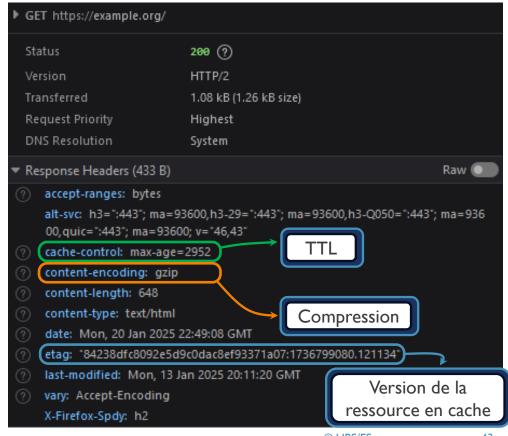




Origin Server

GESTION DU CACHE

- En-tête HTTP pour la gestion de mise en cache
 - Intervient au niveau du cache navigateur mais également proxy, CDN, etc...
- Permet de spécifier si la mise en cache est autorisée
 - Identifie également si l'utilisateur peut utiliser des données en cache ou pas
- Plusieurs options possibles



« CACHE-CONTROL : ... ? »

« private »

- Correspond généralement a des données privées
 - Information personnels → compte personnel ENT
- Ne permet pas la mise en cache
 - Par l'utilisateur
 - Par un agent intermédiaire (CDN, proxy)

« public »

- Données considérées comme publics
- Permet la mise en cache générale

((no-store))

- Ne permet pas la mise en cache
 - Toute demande utilisateur doit passer par le serveur d'origine
- Correspond aux données sensibles → compte bancaire

« no-cache »

- Utilisation des données en cache s'ils sont à jour
- Utilisation du tag ETag → jeton unique de version de la ressource en cache
- Comparaison du ETag avec la version sur le serveur
 - S'ils sont identiques → les données du cache sont utilisés
 - Sinon → Récupération de la nouvelle version sur le serveur

« CACHE-CONTROL : ... ? »

« max-age »

- Correspond à la durée de vie de la donnée dans le cache
 - Valeur exprimée en secondes
- Ex: 1800 → 30 minutes de validité
 - < 30 minutes → la version en cache est utilisée</p>
 - > 30 minutes → la donnée est « périmée »
 - La requête doit aller au serveur d'origine

« s-maxage »

- Directive spécifiquement destinée aux caches partagés
 → CDN
- Détermine la durée de vie de la ressource dans le cache
- Remplace l'option « max-age » des clients individuels

BUT INFO - R6.B.05 © UBS/ES 45

ROUTAGE CDN

- Plusieurs méthodes de déploiement de CDN
 - CDN basés-DNS
 - CDN basés-URL
- Ces approches utilisent des méthodes de routage pour orienter les requêtes

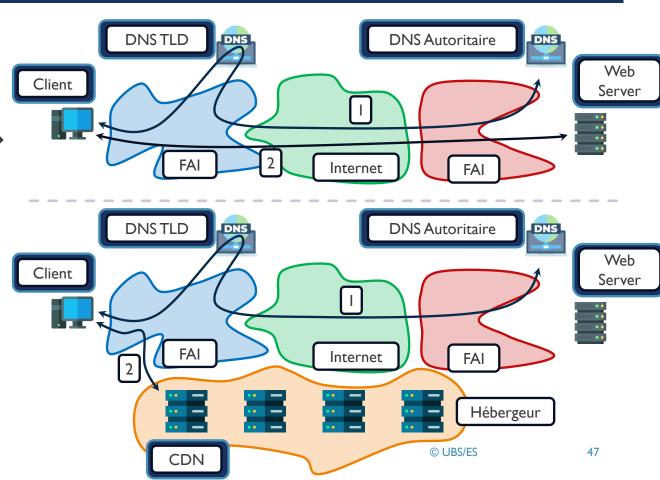
CDN basés-DNS

- Basé routage DNS : Accord entre l'hébergeur et les gestionnaires DNS
- Approche Akamai : Pas d'intervention DNS nécessaire
- CDN basés-URL
 - Équilibrage de charge : point de connexion TCP proche du serveur
 - Routage sur le contenu : point de connexion TCP proche du client

CDN BASÉS-DNS

Routage basé-DNS

- Sélection du CDN lors du translation nom d'hôte → adresse IP
- Utilisation d'un serveur DNS particulier
 - Traite le nom d'hôte et la source
 - Calcule sur plusieurs métriques
 - RTT, charge de serveur, temps de réponse, etc...
- Approche transparente pour l'utilisateur



CDN BASÉS-DNS

Approche Akamai

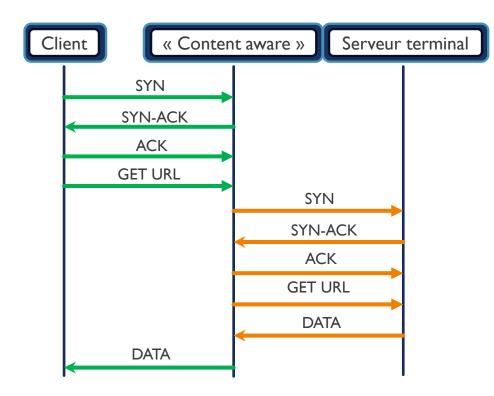
- Utilisation d'un protocole propriétaire de redirection de trafic envers ses CDN SANS intervention des serveurs DNS
- Utilisation d'un nom de domaine classique
- Page web contient des ressources avec un domaine spéciale vers un cache Akamai spécifique
 - http://cnn.com/a.gif \rightarrow http://a128.g.akamai.net/7/23/cnn.com/a.gif
- Requêtes DNS du navigateur vers lu serveur cache de proximité

BUT INFO - R6.B.05 © UBS/ES 44

CDN BASÉS-URL

Équilibrage de charge serveur

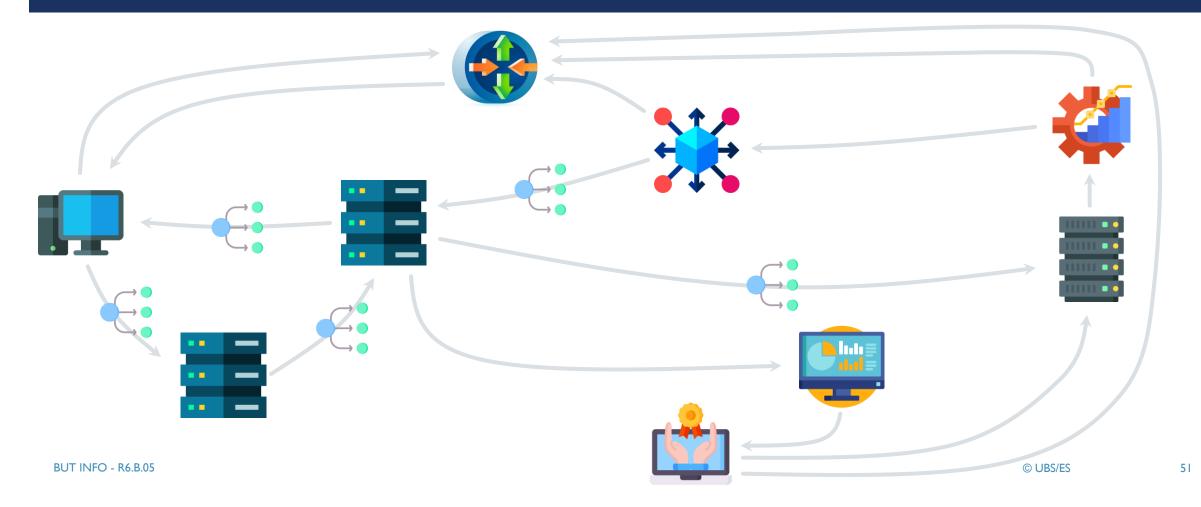
- Deux approches de load balancing
 - Niveau 4 :TCP connexions sont relayés par le load balancer
 - « Content-unaware »
 - Le même serveur terminal maintien la connexion TCP et répond
 - Aucun autre serveur n'intervient
 - Load balancing sur l'adresse IP source, le port TCP source , etc...
 - Niveau 7 : Clôture des connexions TCP par le load balancer
 - « Content-aware »
 - Deux sessions TCP → Client load balancer et load balancer serveur terminal
 - Plusieurs serveurs peuvent répondre aux requêtes
 - Load balancing basé sur l'URL complet

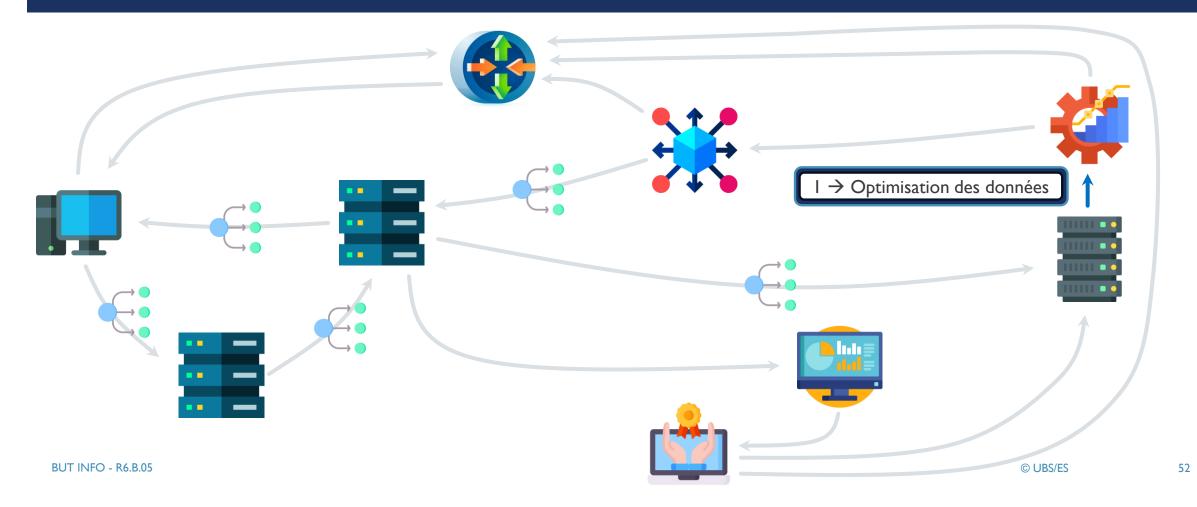


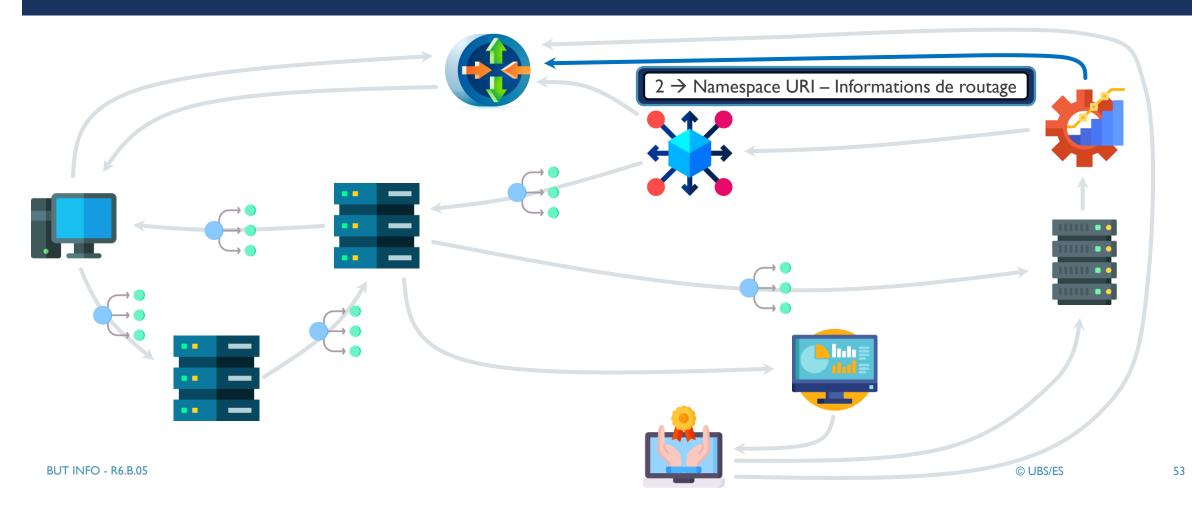
CDN BASÉS-URL

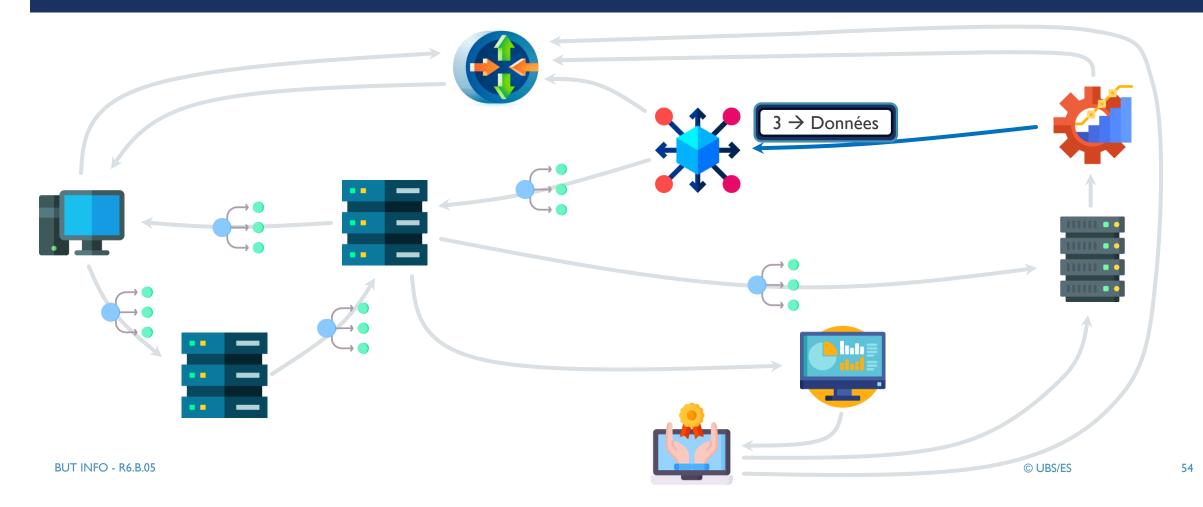
Routage sur le contenu

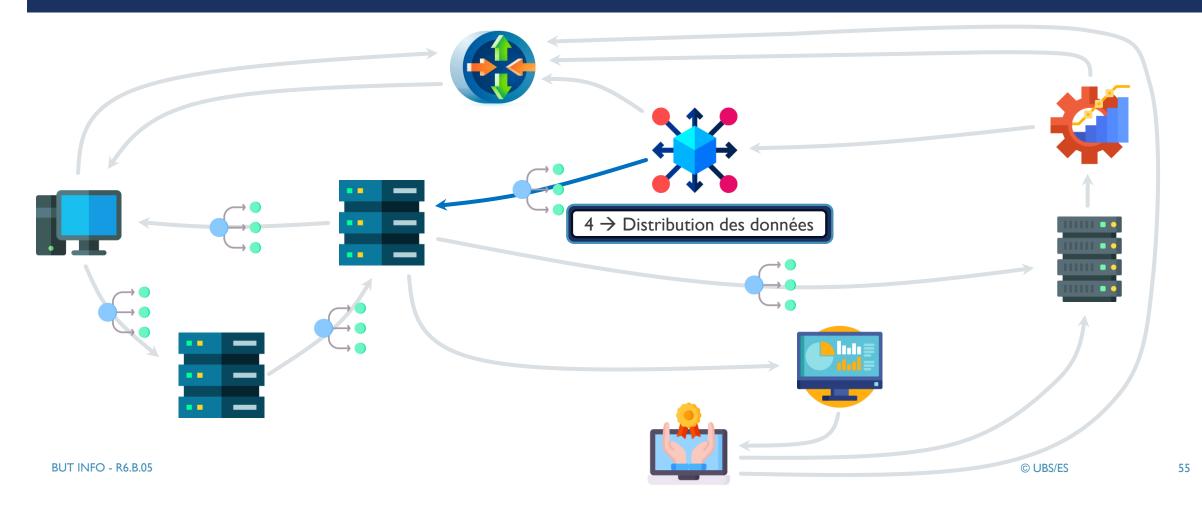
- Utilisation de « routeurs de contenu »
 - Équipements capables de router le trafic vers le meilleur cache basé sur l'URL
- Utilisation de TCP en mode « content-aware »
 - Clôture des sessions TCP entre chaque routeur
 - Utilisation d'un protocole de gestion de livraison de contenu
 - Extraction de l'URL par le premier routeur puis propagé via un protocole spécifique

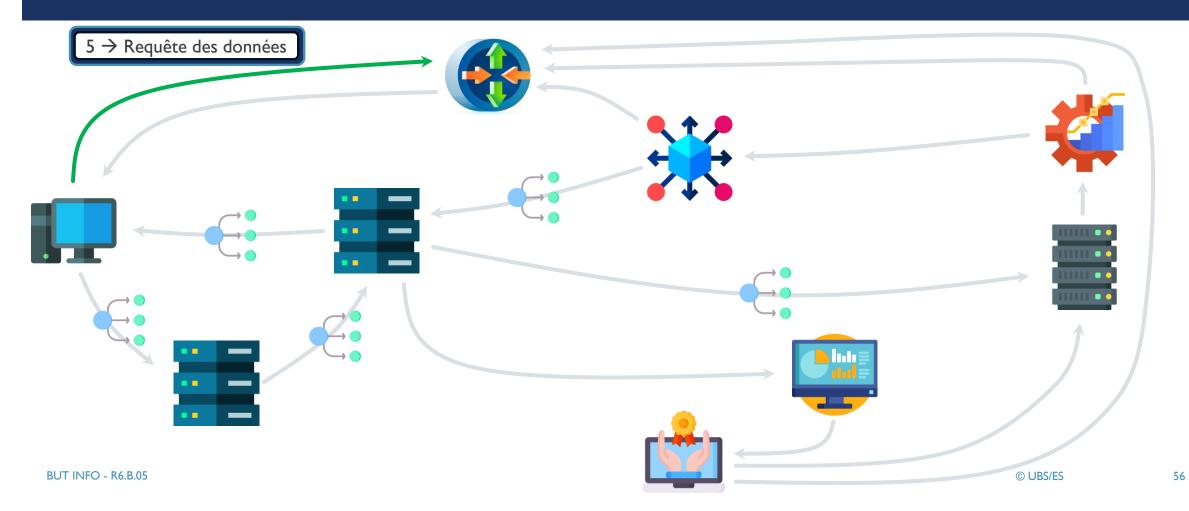


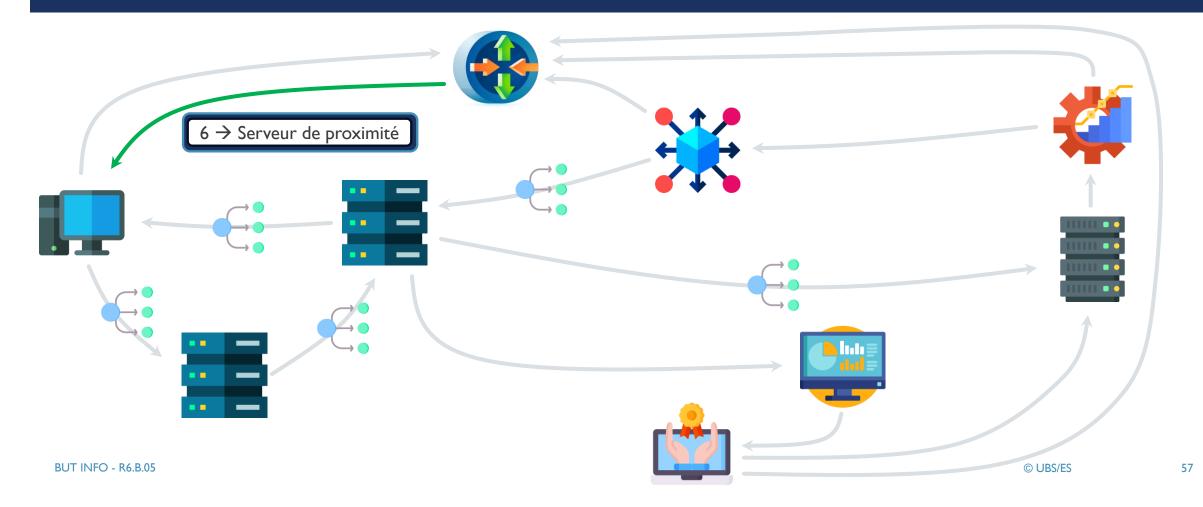


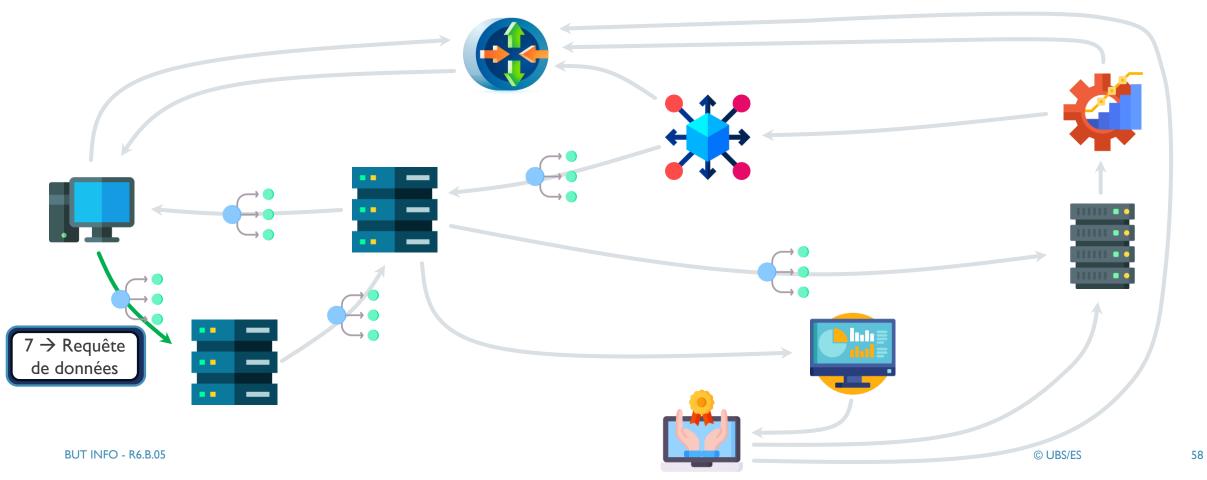


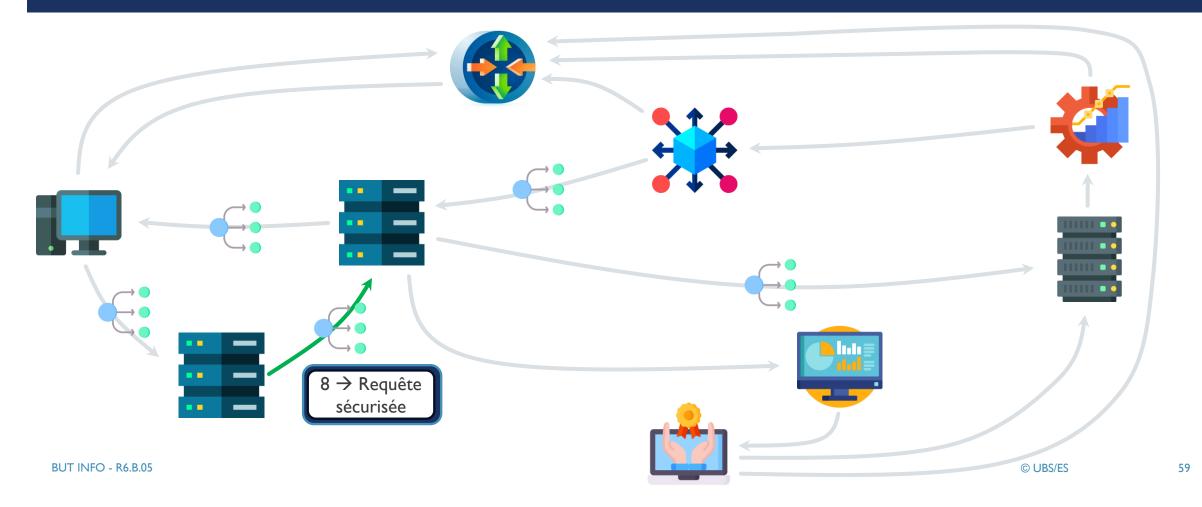


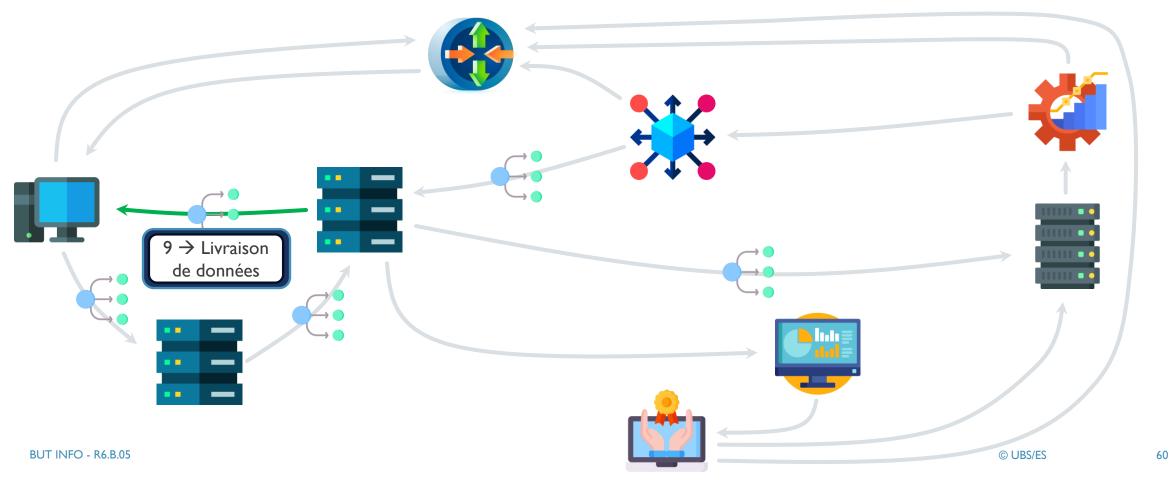


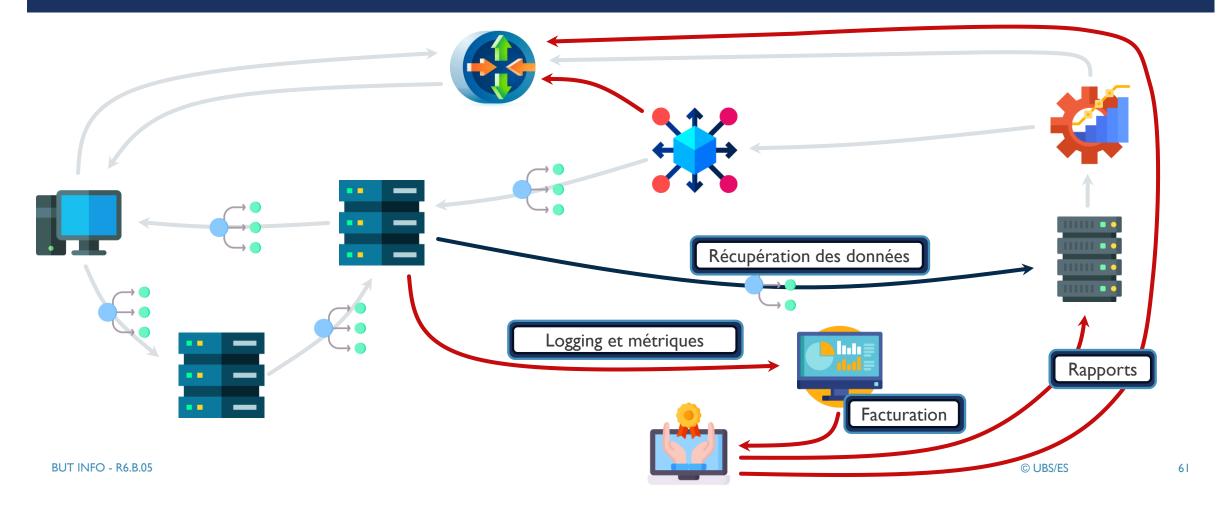


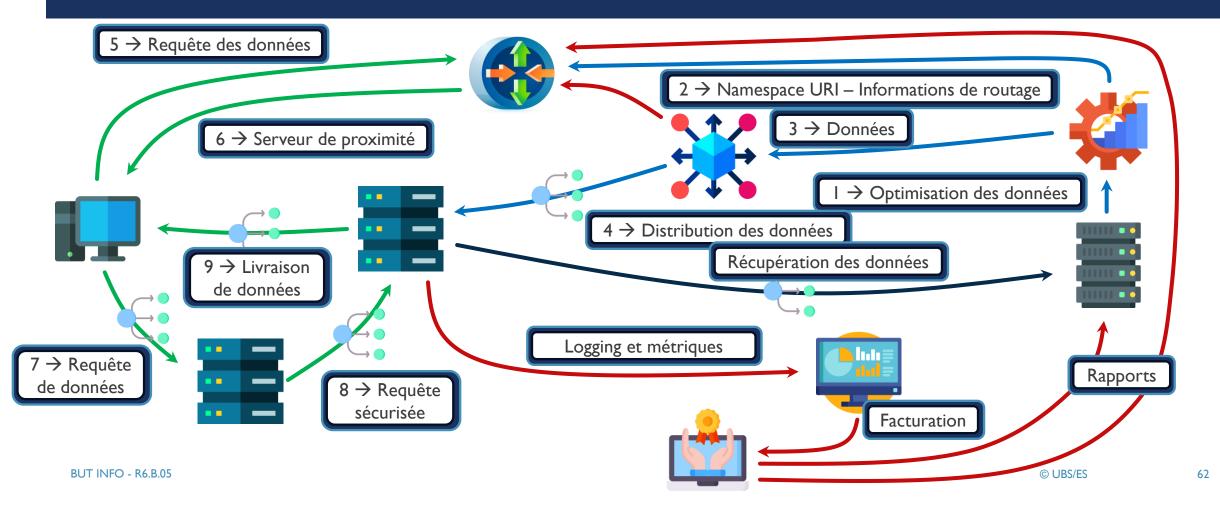












POURQUOI UTILISER UN CDN?









PERFORMANCES



- Accélération des performances
 - En moyenne réduction de 50 % de la latence
- Placement généralement aux points d'échange Internet (IXP)
 - Points d'échange entre réseaux des FAI
 - Mutualisation des ressources des réseaux FAI
- Placement également dans les datacenters
 - Placement dépendant du niveau de trafic / emplacements stratégiques

- Diffusion de contenue rapide et efficace
- Trois optimisations :
 - Réduction de la distance entre le client et les données
 - Optimisations d'infrastructure (SSD, load balancing, etc...)
 - Réduction des tailles de fichiers pour réduire le temps de transfert

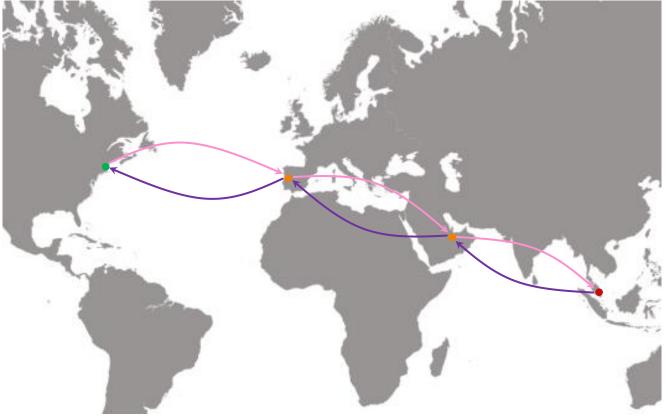
BUT INFO - R6.B.05 © UBS/ES 64





Situation sans CDN

Client à New York – Serveur à Singapour





Situation sans CDN

- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
 - Distance trop longue pour une liaison directe





Situation sans CDN

- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
- 250 ms New York \rightarrow R1 \rightarrow R2 \rightarrow Singapour
 - Ajout de latence par les routeurs

BUT INFO - R6.B.05

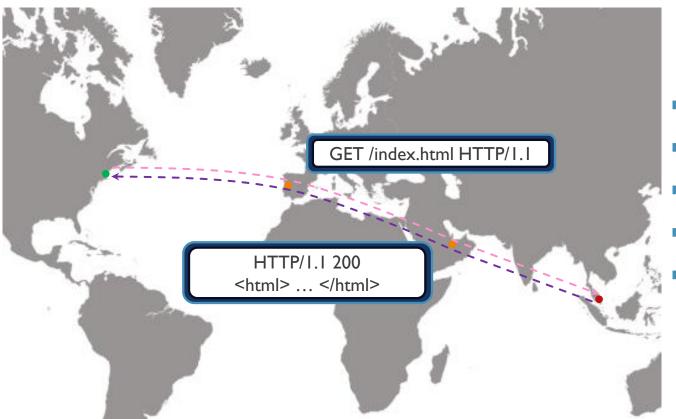
© UBS/ES





Situation sans CDN

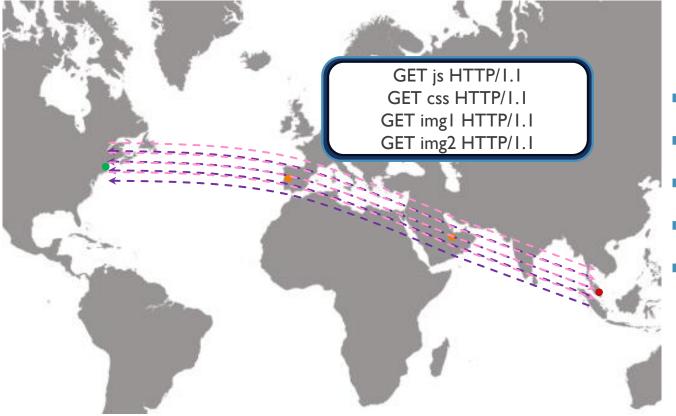
- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
- 250 ms New York \rightarrow R1 \rightarrow R2 \rightarrow Singapour
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 750 ms
 - Echange de trois messages distincts à 250 ms chacun





Situation sans CDN

- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
- 250 ms New York \rightarrow R1 \rightarrow R2 \rightarrow Singapour
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 750 ms
- Le site web possède 5 ressources
 - La page HTML → 500 ms
 - Requête → 250 ms
 - Réponse \rightarrow 250 ms





Situation sans CDN

- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
- 250 ms New York \rightarrow R1 \rightarrow R2 \rightarrow Singapour
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 750 ms
- Le site web possède 5 ressources
 - La page HTML → 500 ms
 - Fichier CSS, fichier JS et 2 images → 1250 ms
 - Requête → 250 ms chacun
 - Réponse asynchrone → 250 ms chacun

En parallèle





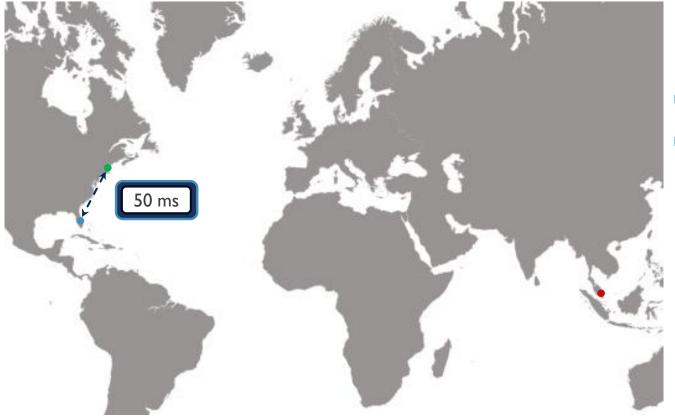
Situation sans CDN

- Client à New York Serveur à Singapour
- Présence de trois routeurs intermédiaires
- 250 ms New York \rightarrow R1 \rightarrow R2 \rightarrow Singapour
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 750 ms
- Le site web possède 5 ressources
 - La page HTML → 500 ms
 - Fichier CSS, fichier JS et 2 images → 1250 ms



Situation avec CDN

Client à New York – CDN à Miami



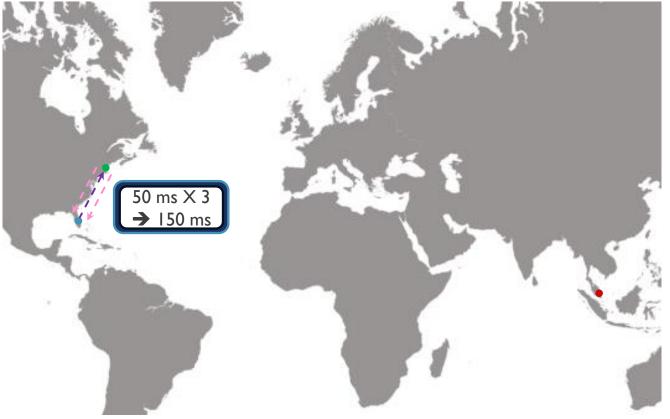


Situation avec CDN

- Client à New York CDN à Miami
- 50 ms New York → Miami
 - Communication directe, pas de routeurs

BUT INFO - R6.B.05

© UBS/ES





Situation avec CDN

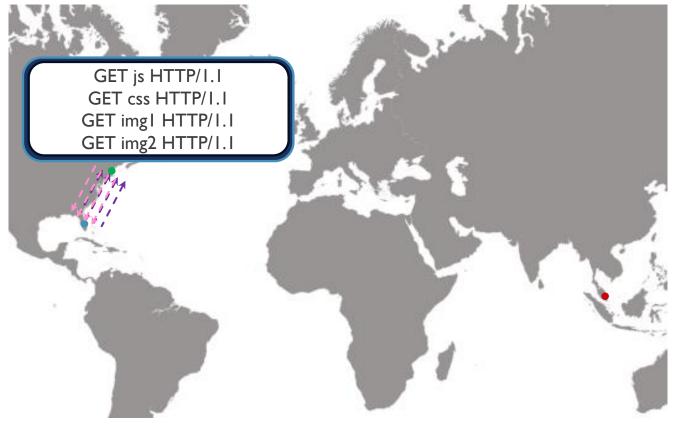
- Client à New York CDN à Miami
- 50 ms New York → Miami
 - Communication directe, pas de routeurs
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 150 ms
 - Echange de trois messages distincts à 50 ms chacun





Situation avec CDN

- Client à New York CDN à Miami.
- 50 ms New York → Miami
 - Communication directe, pas de routeurs
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 150 ms
- Le site web possède 5 ressources
 - La page HTML → 100 ms
 - Requête → 50 ms
 - Réponse → 50 ms

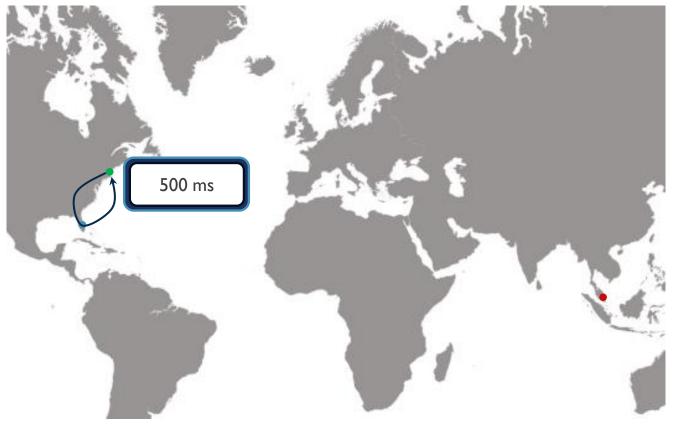




Situation avec CDN

- Client à New York CDN à Miami.
- 50 ms New York → Miami
 - Communication directe, pas de routeurs
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 150 ms
- Le site web possède 5 ressources
 - La page HTML → 100 ms
 - Fichier CSS, fichier JS et 2 images → 250 ms
 - Requête → 50 ms chacun
 - Réponse asynchrone → 50 ms chacun

En parallèle





Situation avec CDN

- Client à New York CDN à Miami.
- 50 ms New York → Miami
 - Communication directe, pas de routeurs
- HTTP \rightarrow TCP \rightarrow 3-way handshake \rightarrow 150 ms
- Le site web possède 5 ressources
 - La page HTML → 100 ms
 - Fichier CSS, fichier JS et 2 images → 250 ms





• Avec CDN \rightarrow **500 ms**

Réduction de 2000 ms

 Le CDN maintient son cache à jour à partir des données du serveur d'origine



PERFORMANCES – RÉDUCTION DE TAILLE DES FICHIERS



- Gros fichiers → transfert plus long
- Deux avantages à la réduction
 - Augmentation de la Vitesse de transfert
 - Réduction de l'emprunte disque du cache
- Deux approches
 - Minimisation
 - Suppression de l'espace « inutile » dans du code

```
// Function to say happy birthday to a user
// also incrementing their age at the same time
// and returning the updated value
function birthday(name, age)

{
    age = age + 1;
    console.log("Happy birthday " + name + ", " + age + " today!!");
    return age;
}

age = birthday("Edward", 30);
```

1 function birthday(a,d){return d+=1,console.log("Happy birthday "+a+", "+d+" today!!"),d}age=birthday("Edward",30);

- Compression
 - Réduction de la taille des fichiers \rightarrow GZip

BUT INFO - R6.B.05 © UBS/ES 79

RÉDUCTION DES COÛTS

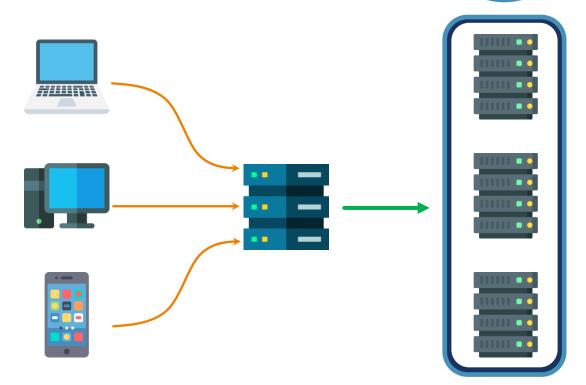


- Réduction du cout de transfert de données
 - Du au positionnement entre l'utilisateur et le serveur d'origine
 - Réduction de la quantité de trafic avec les serveurs d'origine
- Réduction de la latence
 - Stockage au plus près de l'utilisateur
 - Cf exemple New York Singapour

- Réduction du cout financier du serveur d'origine
 - Facturation de la bande passante utilisé
 - Plus de CDN → moins de trafic avec le serveur d'origine
 - Moins de frais

FIABILITÉ

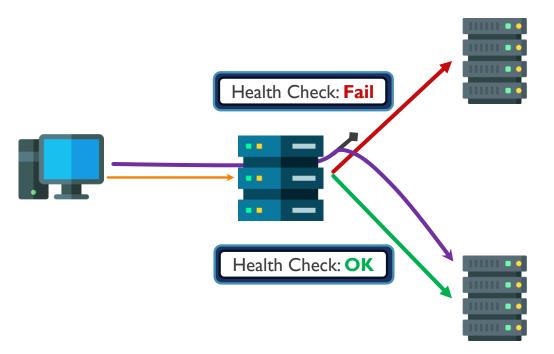
- Plusieurs CDN pour un serveur d'origine
 - Permet de combatte les problèmes
 - Pannes réseau / matériel, congestion, attaques ...
 - Utilisation de plusieurs approches
 - Load balancing
 - Basculement intelligent
 - Réorientation du trafic
 - Distribution multi-datacenter



FIABILITÉ – BASCULEMENT INTELLIGENT



- Système de basculement (failover)
 - Empêcher la perte du trafic en cas de serveur indisponible
 - Redirection du trafic vers un serveur fonctionnel
 - Permettre la continuité de service

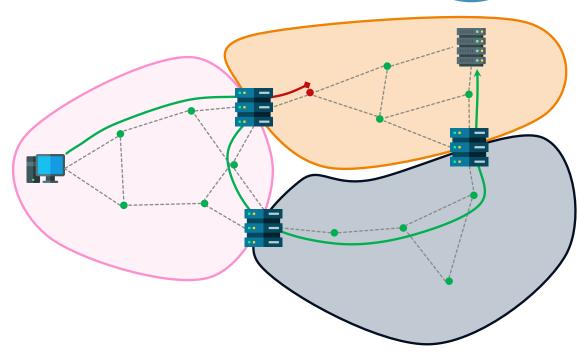


BUT INFO - R6.B.05

FIABILITÉ – RÉORIENTATION DU TRAFFIC



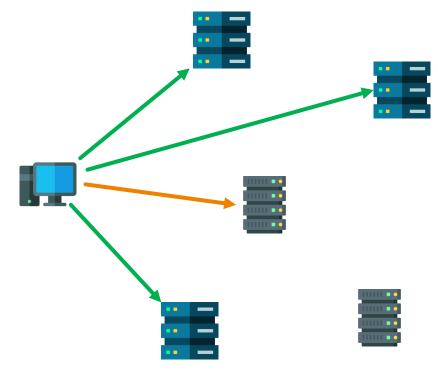
- Trouver le chemin optimal vers la destination
 - Éviter tout congestion, panne, etc ...
 - Fonctionnement similaire au GPS
 - Empêcher la perte du trafic en cas de serveur indisponible
 - Redirection du trafic vers un serveur fonctionnel
 - Permettre la continuité de service
- Parfois besoin de négociations si changement de Réseau via les CDN de périphérie
 - Peut engendrer de la latence



FIABILITÉ – DISTRIBUTION MULTI-DATACENTER



- Utilisation de l'approche Anycast au lieu que l'Unicast
 - Anycast → Plusieurs destinataires peuvent recevoir le message
 - Unicast → Un destinataire seul peut recevoir le message
- Permet de joindre plusieurs datacenters sur une adresse IP
 - Réponse déterminée sur une méthode de priorisation
- Apporte une protection contre le DDoS
 - Absorbé par chacun des centres de données du CDN

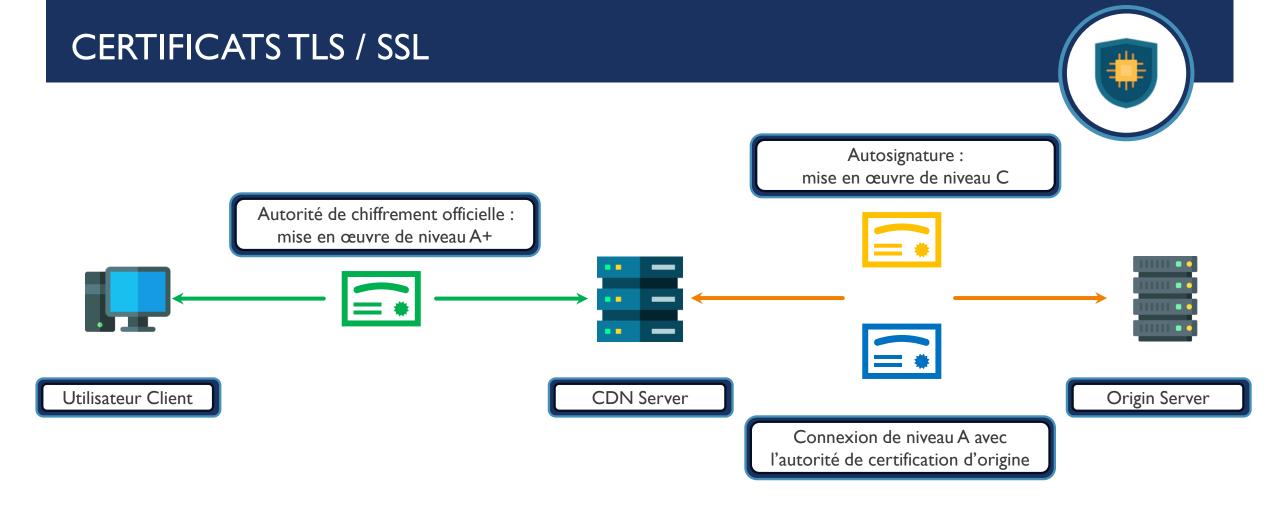


RÉSILIENCE FACE AUX ATTAQUES



- Défense adaptée contre les attaques DoS et DDoS
- Utilisation des certificats TLS / SSL
 - Niveau élevé d'authentification
 - Chiffrement des données
 - Confirmation de l'intégrité





BUT INFO - R6.B.05

EXEMPLES DE CDN

Publics

- Amazon
 - AWS CloudFront
- Cloudflare
 - Cloudflare CDN
 - 330 CDN dans le monde (statique + dynamique)
- Akamai
 - Fournisseur très connu et très utilisé dans le monde
 - Plusieurs solutions possibles

FAI

- Mise en place de CDN coté FAI
 - Apporte les avantages des CDN au plus près des clients des fournisseurs
- Orange Business
 - CDN à destination des entreprises
 - Utilisation de « Aura Network Solutions »
- SFR Business Team
 - CDN à destination des abonnées grand public
 - Utilisation d'infrastructure propre